

ENONCE DE PROJET ©

Matière : Fouille de données

Enseignants : Taoufik Ben Abdallah

Discipline : 2^{ème} année Génie Informatique

Tarek Ben Said

Année Universitaire : 2025-2026 / S1

Carthage Assurances

Dans le cadre de sa stratégie de tarification et de gestion proactive des risques, **Carthage Assurances** souhaite intégrer à son système décisionnel un modèle de **prédiction de sinistre habitation**. L'objectif est d'estimer, pour chaque contrat, la probabilité qu'un bâtiment subisse au moins un incident (réclamation) pendant la période couverte. Les cas d'usage incluent :

- **Personnalisation des offres** (ajustement de prime, remises conditionnelles, options de garanties),
- **Souscription assistée** (alerte en cas de risque élevé),
- **Prévention & fidélisation** (campagnes ciblées, conseils de mitigation).

Jeu de données fourni

Un fichier **Excel** intitulé *insurance* est mis à disposition et comporte deux feuilles : **Feuille "train" : 5014** observations, et **Feuille "test" : 2147** observations. Chaque observation décrit un bâtiment et son contrat via **11 variables explicatives** et **1 variable cible binaire (Tableau1)**

Tableau 1 : description des attributs

Attribut	Type	Description
policy_id	Catégorielle	Identifiant du contrat/client
Year	Numérique	Année d'observation de l'état du bâtiment
coverage_period	Binaire	Durée de couverture (1.0= 12 mois, 0.5= 6 mois)
is_residential	Binaire	Bâtiment à usage résidentiel
is_finished_and_fenced	Catégorielle	Bâtiment peint/achevé et clôturé
has_garden	Binaire	Présence d'un jardin
locality	Catégorielle	Zone d'implantation : rurale ou urbaine
area_m2	Numérique	Superficie du bâtiment (m ²)
structure_type	Catégorielle	Type de structure: Fire-resistive, Non-combustible, Ordinary, Wood-framed
window_count	Catégorielle	Nombre de fenêtres (0 autorisé ; « without » → 0)
risk_score	Numérique	Score du risque de sinistre sur la période assurée
geo_zone	Catégorielle	Code géographique du bâtiment assuré
Claim	Binaire	Attribut Target : oui si au moins une réclamation durant la période d'assurance, sinon non

Le **Figure 1** montre un extrait du jeu de données *insurance*.

	A	B	C	D	E	F	G	H	I	J	K	L	M
	policy_id	year	age_per	resident	hed_and	has_garder	locality	area_m2	ructure_ty	ndow_cour	risk_score	Geo_Code	claim
1													
2													
3													
4	H13501	2012	1	1	N/V	V	U	1240	Wood-frai	without		75117	non
5	H14962	2012	1	0	N/V	V	U	900	Non-comb	without		62916	non
6	H17755	2013	1	1	V/N	O	R	4984	Non-comb	4		31149	oui
7	H13369	2016	0,5	0	N/V	V	U	600	Wood-frai	without		6012	oui
8	H12988	2012	1	0	N/V	V	U	900	Non-comb	without		57631	non
9	H3052	2016	0,5	0	N/V	V	U	2675	Ordinary	without		38185	non
10	H16831	2014	1	1	V/N	O	R	2500	Non-comb	2		78423	non
11	H19427	2015	1	0	V/N	O	R	2500	Non-comb	7		31555	oui
12	H3893	2013	1	0	N/V	V	U	680	Non-comb	without		39300	non
13	H14092	2013	1	0	N/V	V	U	605	Non-comb	without		83129	non
14	H2379	2016	0,5	0	V/V	V	U	250	Fire-resist	without		13117	non
15	H16676	2016	0,5	1	V/N	O	R	4392	Ordinary	4		92032	non
16	H18198	2012	0,5	0	V/N	O	R	5354	Non-comb	5		64348	oui
17	H2571	2016	0,5	0	V/N	O	R	600	Fire-resist	4		63032	non
18	H3729	2012	1	0	V/V	V	U	550	Fire-resist	without		42187	non
19	H15094	2013	0,5	1	V/N	O	R	2340	Ordinary	7		92051	oui
20	H16112	2016	1	1	V/N	O	R	2000	Wood-frai	7		75118	non
21	H12660	2015	1	0	V/N	O	R	1076	Ordinary	4		59350	non

Figure 1 : Extrait du jeu de données *insurance*

Travail à faire :

- 1/ Analyser et visualiser les données
- 2/ Nettoyer, **si nécessaire**, les données
- 3/ Sélectionner, **si nécessaire**, les descripteurs les plus discriminants
- 4/ Encoder les données et générer un ou plusieurs modèle(s) de prédiction en appliquant des **techniques d'apprentissage supervisée** (DecisionTreeClassifier, SVC, LogisticClassifier, GradientTreeBoosting, MLPClassifier, RandomForestClassifier, etc.)
- 5/ Évaluer les performances du/des modèle(s) obtenu(s). **Interpréter les résultats**

Barème d'évaluation :

EDA et Data Preprocessing			Apprentissage automatique et validation			
EDA & interprétation	Data preprocessing	Innovation	Solution(s) proposée(s)	Estimation des performances	Innovation	Présentation & discussion
3 pts	3 pts	2.5 pts	3 pts	3 pts	2.5 pts	3 pts

✓ Chaque groupe doit être obligatoirement composé de *quatre* candidats



Chaque groupe doit préparer une présentation PowerPoint comprenant trois parties :

1. **Contexte et motivation** : présenter le cadre du projet.
2. **Travail réalisé** : décrire les tâches effectuées, en détaillant les étapes suivies, les choix réalisés, et en interprétant les résultats obtenus à l'aide de diverses métriques et études comparatives.
3. **Conclusion et perspectives** : proposer des pistes d'amélioration pouvant être utiles pour optimiser les résultats obtenus.

La présentation ne doit pas dépasser *10 minutes*, et il est recommandé de ne pas inclure de captures d'écran des codes.

Livrables (sur Moodle) :

Livrable 1 (16/11/2025)	Livrable 2 (14/12/2025)
ipynb de la partie EDA & Data Preprocessing	ipynb de tout le projet

Soutenance : 16-17-18 Décembre 2025

Bon Travail ♣